UNIVERSIDAD REGIONAL AUTÓNOMA DE LOS ANDES

UNIANDES

PROCESO DE TITULACIÓN COMPLEXIVO – SEMINARIO

CARRERA: **SOFTWARE**

ASIGNATURA: INGENIERÍA DE SOFTWARE CON IA GENERATIVA: DESARROLLO DE APLICACIONES INTELIGENTES

CASO N.º: 01 – GRUPO 1

TEMA DEL CASO: Asistente Inteligente de Titulación y Normativa Académica

(RAG sobre normativa de educación superior – Agente de trámites académicos)

Tipo de producto: Asistente conversacional con RAG

Antecedentes:

Los estudiantes de los últimos niveles enfrentan dudas recurrentes sobre requisitos de titulación, modalidades (examen complexivo, trabajo de integración curricular), prácticas preprofesionales, vinculación con la sociedad, plazos y homologaciones. La información existe, pero está dispersa entre la Ley Orgánica de Educación Superior (LOES), el Reglamento de Régimen Académico del Consejo de Educación Superior (CES) y los reglamentos internos de cada institución. Las secretarías académicas responden las mismas preguntas cientos de veces por período y los estudiantes reciben a menudo respuestas incompletas o contradictorias.

Objetivo del caso:

Construir un asistente web conversacional que responda consultas sobre titulación y normativa académica fundamentándose exclusivamente en los documentos oficiales de su base de conocimiento, citando el artículo y el documento de origen, e incorporar un agente que genere una lista de verificación personalizada de requisitos pendientes según la situación del estudiante.

Actividades para el estudiante:

Resultado de aprendizaje: el estudiante diseña, construye y despliega una plataforma inteligente basada en RAG y en un agente de alcance controlado que responde a un problema

real, aplicando ingeniería de prompts, integración con modelos generativos, calidad, seguridad y gestión de proyectos de software.

Fase 1 – Definición del problema y diseño de la solución inteligente (Semana 1)

Levantar al menos 15 preguntas frecuentes reales (encuesta breve o entrevista con secretaría). Redactar la propuesta, historias de usuario con criterios de aceptación y requisitos no funcionales (tiempo de respuesta, trazabilidad de la fuente, privacidad). Diseñar la arquitectura (frontend, backend, modelo, base vectorial, agente) y justificar el modelo generativo elegido. Descargar y catalogar las fuentes en el inventario de la base de conocimiento.

Fase 2 – Construcción del MVP e integración con IA generativa (Semana 2)

Implementar el chat con un system prompt que delimite el rol (orientador académico), el tono y la obligación de declarar cuando no conoce la respuesta. Probar al menos tres variantes de prompt sobre 10 preguntas y documentar cuál reduce más las respuestas inventadas. El backend (FastAPI o equivalente) expone los endpoints del producto y el frontend web los consume; la clave del modelo reside únicamente en el backend, cargada desde variables de entorno (.env excluido del repositorio). Se registra en el repositorio Git, con commits de los tres integrantes, la evidencia técnica de la semana: capturas, versiones del prompt comparadas y decisiones tomadas.

Fase 3 – Conocimiento especializado: RAG, agente y calidad (Semana 3)

Fragmentar la LOES, el Reglamento de Régimen Académico y los reglamentos institucionales por artículo, con metadatos (documento, artículo, fecha de vigencia). Implementar RAG con cita obligatoria. Construir un agente con las herramientas consultar_requisitos(modalidad), calcular_plazo(fecha_inicio, dias_habiles) y generar_checklist(perfil_estudiante); debe rechazar consultas fuera del ámbito académico y derivar a secretaría los casos que requieren resolución administrativa. Evaluar con 20 preguntas de referencia (respuesta y artículo esperados).

Fase 4 – Despliegue y validación (Semana 4)

Pruebas mínimas: preguntas con respuesta, preguntas sin respuesta (abstención), preguntas ambiguas (pedir aclaración) e intentos de inyección de instrucciones. Desplegar en la nube

(Render, Railway, Hugging Face Spaces u otra plataforma aprobada) con las credenciales como variables de entorno de la plataforma, nunca en el código. Ejecutar y documentar las pruebas funcionales contra la URL desplegada (resultado esperado y obtenido) y entregar el README con problema, arquitectura, instalación, variables de entorno, URL, limitaciones, declaración de uso de IA y aporte de cada integrante.

Fase 5 – Sustentación y comunicación de resultados

Demostración en vivo y respuesta a: ¿qué porcentaje de las preguntas de referencia se respondió con la cita correcta? ¿En qué consultas falló el sistema y por qué? ¿Qué riesgos existen si un estudiante confía en una respuesta desactualizada y cómo los mitiga la solución?

Indicadores mínimos de calidad del caso:

- Al menos el 80 % de las 20 preguntas de referencia se responde correctamente y con la cita del artículo correcto.
- El 100 % de las preguntas sin respuesta en la normativa produce una abstención explícita.
- El agente rechaza el 100 % de las consultas fuera del ámbito académico y de los intentos de inyección probados.

Documentos adicionales:

Temas técnicos que el equipo debe dominar:

- Fragmentación por estructura del documento y metadatos de vigencia
- Citas y trazabilidad de la fuente en respuestas generadas
- Agentes con herramientas (function calling) y límites de alcance
- Evaluación de RAG: recuperación, fidelidad y abstención

Fuentes oficiales de la base de conocimiento (APA 7.ª ed.; verificar vigencia a la fecha de uso):

- Asamblea Nacional del Ecuador. (2010). Ley Orgánica de Educación Superior. Registro Oficial Suplemento 298, 12 de octubre de 2010, y reformas vigentes. https://www.ces.gob.ec
- Consejo de Educación Superior. (s. f.). Reglamento de Régimen Académico (codificación vigente y reformas). Recuperado el 12 de octubre de 2026, de https://www.ces.gob.ec

- Universidad Regional Autónoma de los Andes. (s. f.). Reglamentos institucionales de titulación, prácticas preprofesionales y vinculación. Recuperado el 12 de octubre de 2026, de https://www.uniandes.edu.ec

Referencias académicas específicas del caso (APA 7.ª ed.):

- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Artículo 248. https://doi.org/10.1145/3571730
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). Lost in the middle: How language models use long contexts. Transactions of the Association for Computational Linguistics, 12, 157–173. https://doi.org/10.1162/tacl_a_00638

Bibliografía base del seminario (común a todos los casos, APA 7.ª ed.):

- Anthropic. (2024, 19 de diciembre). Building effective agents. https://www.anthropic.com/research/building-effective-agents
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. En Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations (pp. 150–158). ACL. https://arxiv.org/abs/2309.15217
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. arXiv. https://arxiv.org/abs/2312.10997
- Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. En Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (pp. 79–90). ACM. https://doi.org/10.1145/3605764.3623985
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En Advances in Neural Information Processing Systems 33 (pp. 9459–9474). https://arxiv.org/abs/2005.11401
- OWASP Foundation. (2025). OWASP Top 10 for Large Language Model Applications 2025. https://genai.owasp.org/llm-top-10/

- Sommerville, I. (2016). Software engineering (10.ª ed.). Pearson.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. En International Conference on Learning Representations (ICLR 2023). https://arxiv.org/abs/2210.03629

Opcional: si el equipo desea aplicar este caso a otra base de conocimiento del mismo dominio, lo puede hacer. Requiere aprobación previa del docente.